Clase 12: Datos faltantes, outliers y transformaciones

MCAR, MAR, MNAR | Detección de outliers | Imputación | Transformaciones

Nicolás Sidicaro

Ciencia de Datos para Economía y Negocios | FCE-UBA

¿Por qué importa la calidad de los datos?

El problema

Basura entra, basura sale

Situaciones típicas con datos reales

- La EPH tiene **ingresos en cero** para personas que no responden.
- Un dataset de empresas tiene **ventas negativas** por errores de carga.
- Hay personas con **edad = 999** o **salario = 0** que distorsionan todo.
- Faltan datos, pero **no al azar**: los más ricos tienden a no declarar ingresos.

La buena noticia

Con un **framework claro** para diagnosticar y tratar estos problemas, podemos tomar decisiones informadas en lugar de ignorarlos (o peor, no darnos cuenta).

Hoja de ruta de la clase

1. **Datos faltantes**: tipos (MCAR, MAR, MNAR), diagnóstico y visualización.
2. **Outliers**: detección con IQR y z-score, criterios de decisión.
3. **Framework de decisión**: cuándo eliminar, imputar o mantener.
4. **Transformaciones**: log, estandarización, normalización, escalado.
5. **Justificación e impacto**: cómo reportar y documentar estas decisiones.

Dataset de ejemplo

Vamos a trabajar con un dataset simulado de empresas argentinas:

```r
empresas <- tibble(
  empresa   = paste0("Empresa_", 1:200),
  sector    = sample(c("Industria", "Comercio", "Servicios", "Agro"),
                     200, replace = TRUE),
  empleados = round(rlnorm(200, meanlog = 3.5, sdlog = 1.2)),
  ventas_mm = round(rlnorm(200, meanlog = 2, sdlog = 1.5), 1),
  antiguedad = sample(1:80, 200, replace = TRUE)
)

# Introducir missings y outliers realistas
empresas$ventas_mm[sample(1:200, 20)] <- NA        # 10% NA
empresas$empleados[sample(1:200, 10)] <- NA         # 5% NA
empresas$empleados[c(5, 42)] <- c(50000, 75000)    # Outliers
empresas$ventas_mm[c(10, 88)] <- c(5000, 8000)     # Outliers
```

Datos faltantes (missing values)

¿Qué es un NA en R?

Definición

`NA` (*Not Available*) es el valor que R usa para representar **datos faltantes**. No es cero, no es vacío, no es un string: es la *ausencia* de información.

¿Por qué no simplemente ignorarlos?

- Muchas funciones de R devuelven `NA` si hay un solo faltante: `mean(c(1, 2, NA))` da `NA`.
- Si eliminamos filas sin pensar, podemos **sesgar** el análisis.
- El **patrón** de los faltantes importa: no es lo mismo que falten al azar a que falten sistemáticamente.

Funciones básicas para detectar NAs

```r
# ¿Cuántos NAs hay por columna?
empresas |> summarise(across(everything(), ~sum(is.na(.))))
```

```
# A tibble: 1 x 5
  empresa sector empleados ventas_mm antiguedad
    <int>  <int>     <int>     <int>      <int>
1       0      0        10        20          0
```

```r
# Proporción de NAs
empresas |>
  summarise(across(where(is.numeric),
                   ~round(mean(is.na(.)) * 100, 1),
                   .names = "pct_na_{.col}"))
```

```
# A tibble: 1 x 3
  pct_na_empleados pct_na_ventas_mm pct_na_antiguedad
             <dbl>            <dbl>             <dbl>
1                5               10                 0
```

Visualizar el patrón de faltantes

```r
# Mapa de calor de NAs
empresas |>
  mutate(fila = row_number()) |>
  pivot_longer(-fila,values_transform = as.character) |>
  mutate(es_na = is.na(value)) |>
  ggplot(aes(x = name, y = fila, fill = es_na)) +
  geom_tile() +
  scale_fill_manual(values = c("grey90", "tomato"),
                    labels = c("Presente", "Faltante")) +
  labs(x = NULL, y = "Observación", fill = NULL) +
  theme_minimal(base_size = 11)
```

Los tres tipos de datos faltantes

MCAR: Missing Completely At Random

La probabilidad de que un dato falte **no depende de nada**: ni del valor faltante ni de otras variables. Ejemplo: se pierde un formulario por accidente.

MAR: Missing At Random

La probabilidad de que falte depende de **otras variables observadas**, pero no del valor faltante en sí. Ejemplo: las empresas chicas no reportan ventas (falta depende del tamaño, que sí observamos).

MNAR: Missing Not At Random

La probabilidad de que falte depende del **propio valor faltante**. Ejemplo: las personas con ingresos altos no declaran su ingreso *porque* es alto.

¿Por qué importa el tipo?

Consecuencias según el tipo

- **MCAR**: eliminar filas con NAs no genera sesgo (pero se pierde poder estadístico).
- **MAR**: eliminar genera sesgo, pero podemos corregir imputando con las variables observadas.
- **MNAR**: el problema más difícil. Ni eliminar ni imputar simple lo resuelve bien. Requiere modelar el mecanismo de no-respuesta.

Ejemplo económico

En la EPH, si los hogares más ricos no reportan ingresos (**MNAR**), el ingreso promedio estará **subestimado**. Eliminar esas filas empeora el problema.

MAR y MNAR: casos concretos

MAR — Missing At Random: ejemplos

- **Encuesta de hogares (EPH)**: las personas **ocupadas** tienden más a no estar en el hogar al momento de la encuesta y no responden. La no-respuesta depende del **estado ocupacional** (que conocemos por otros miembros del hogar), no del ingreso en sí.
- **Encuestas de satisfacción**: los clientes **jóvenes** completan menos las encuestas post-compra. El missing depende de la **edad** (variable observada), no de la satisfacción.
- **Balances de empresas**: las PyMEs del **sector informal** no publican estados contables. La falta de datos depende del **sector/tamaño** (observables), no necesariamente de las ventas.

¿Qué hacer con MAR?

Como el patrón depende de variables que **sí observamos**, podemos imputar usando esas variables (ej: imputar ingreso usando edad, educación y región).

MNAR: el caso más difícil

MNAR — Missing Not At Random: ejemplos

- **Ingresos altos en la EPH**: los hogares de ingresos altos **sub-reportan o no declaran** sus ingresos *precisamente porque son altos*. El valor faltante depende del propio valor.
- **Evasión fiscal**: las empresas que más evaden son las que menos reportan al fisco. La probabilidad de no declarar depende del **monto evadido**, que es lo que falta.
- **Deserción escolar**: los alumnos que abandonan un programa no completan la encuesta de cierre. Su nivel de aprendizaje (bajo) es lo que causa el missing.
- **Mortalidad en estudios clínicos**: los pacientes más graves fallecen y dejan de reportar datos. El dato falta *porque* el resultado fue el peor posible.

¿Por qué es tan problemático?

No podemos corregir el sesgo solo con las variables que observamos. Las estrategias incluyen: modelos de selección (Heckman), análisis de sensibilidad, o al menos crear una **variable indicadora** del missing y reportar el sesgo potencial.

¿Cómo diagnosticar el tipo? (intuición)

No hay un test definitivo, pero podemos buscar patrones:

```
# A tibble: 4 x 3
  sector        n pct_na_ventas
  <chr>     <int>         <dbl>
1 Agro         50           8
2 Comercio     61           8.2
3 Industria    55          16.4
4 Servicios    34           5.9
```

Razonamiento

Si los NAs de ventas se concentran en ciertos sectores, probablemente sea **MAR**. Si la tasa es similar en todos, podría ser **MCAR**.

Outliers: detección y diagnóstico

¿Qué es un outlier?

Definición

Un **outlier** (valor atípico) es una observación que se aleja significativamente del resto de los datos. Puede ser un error de carga o un dato genuinamente extremo.

El dilema clave

- Si es un **error** (alguien puso un cero de más): hay que corregirlo o eliminarlo.
- Si es un dato **real** (una empresa factura 100x más que el promedio): eliminarlo sesga el análisis.
- **No hay una regla automática**. Requiere criterio del analista y contexto del dominio.

Exploración visual: el primer paso

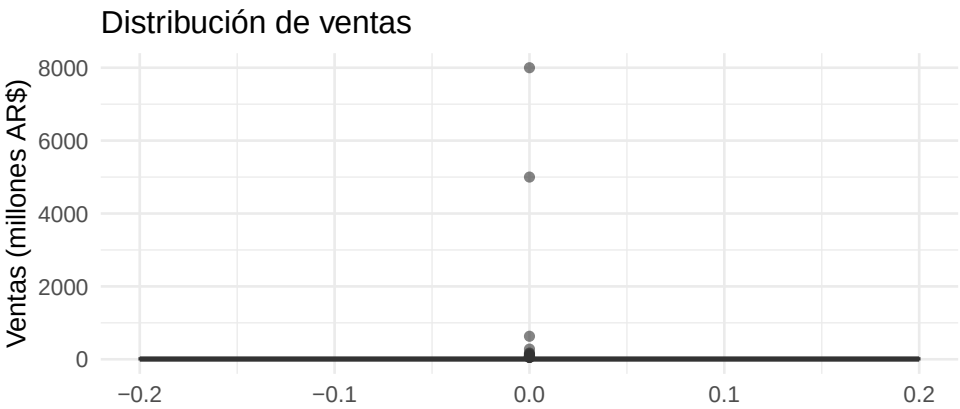

Método 1: Rango intercuartílico (IQR)

La regla del IQR

1. Calcular **Q1** (percentil 25) y **Q3** (percentil 75).
2. **IQR** $=$ Q3 $-$ Q1.
3. Son outliers los valores fuera de: $[Q1 - 1.5 \times IQR,\ Q3 + 1.5 \times IQR]$.

Es el mismo criterio que usa `geom_boxplot()` para los puntos.

¿Por qué 1.5?

Es una convención estadística (propuesta por Tukey). Para datos normales, captura el 99.3% de las observaciones. Se puede usar $3 \times$ IQR para outliers "extremos".

IQR en R

```r
ventas <- empresas$ventas_mm[!is.na(empresas$ventas_mm)]

q1  <- quantile(ventas, 0.25)
q3  <- quantile(ventas, 0.75)
iqr <- IQR(ventas)

lim_inf <- q1 - 1.5 * iqr
lim_sup <- q3 + 1.5 * iqr

cat("Rango aceptable:", round(lim_inf, 1), "a", round(lim_sup, 1), "\n")
```

```
Rango aceptable: -25.1 a 48.8
```

```r
# Identificar outliers
outliers_iqr <- empresas |>
  filter(!is.na(ventas_mm),
         ventas_mm < lim_inf | ventas_mm > lim_sup)
cat("Outliers detectados:", nrow(outliers_iqr))
```

```
Outliers detectados: 21
```

Método 2: Z-score

La idea del z-score

El z-score mide cuántas **desviaciones estándar** un valor está de la media:

$$z_i = \frac{x_i - \bar{x}}{s}$$

Convención: si $|z| > 3$, se considera outlier (asumiendo distribución aproximadamente normal).

Limitaciones

- El z-score supone distribución **simétrica**. Datos de ingresos o ventas suelen tener cola derecha larga.
- La propia media y el desvío se ven afectados por los outliers ("efecto masking").
- Para datos muy asimétricos, es preferible usar el método IQR o trabajar con la transformación logarítmica.

Z-score en R

```r
empresas_zscore <- empresas |>
  filter(!is.na(ventas_mm)) |>
  mutate(z_ventas = (ventas_mm - mean(ventas_mm)) / sd(ventas_mm))

# Outliers con |z| > 3
outliers_z <- empresas_zscore |>
  filter(abs(z_ventas) > 3)

outliers_z |> select(empresa, ventas_mm, z_ventas) |>
  mutate(z_ventas = round(z_ventas, 2))
```

```
# A tibble: 2 x 3
  empresa    ventas_mm z_ventas
  <chr>          <dbl>    <dbl>
1 Empresa_10      5000     6.99
2 Empresa_88      8000    11.3
```

Comparación visual: IQR vs z-score

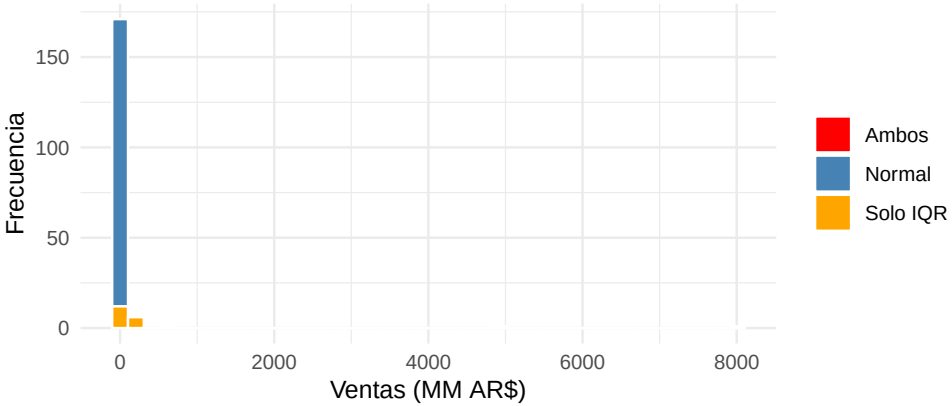

Framework de decisión: ¿qué hacer con los problemas?

El framework: eliminar, imputar o mantener

Las tres opciones

1. **Eliminar**: descartar la fila o el valor problemático.
2. **Imputar**: reemplazar el valor faltante/outlier por una estimación.
3. **Mantener**: dejar el dato como está (quizás es información valiosa).

No hay una respuesta universal

La decisión depende de:

- El **tipo de missing** (MCAR vs MAR vs MNAR).
- Si el outlier es **error o dato genuino**.
- Cuántos datos se pierden al eliminar.
- El **objetivo del análisis** (descripción vs predicción).

Cuándo eliminar

Eliminar está bien cuando...

- Los NAs son **MCAR** y representan un **porcentaje bajo** ($< 5\%$).
- El outlier es claramente un **error de carga** (edad $= 999$, ventas negativas).
- Tenés suficientes datos y perder observaciones no afecta la representatividad.

```r
# Eliminar filas con NA en ventas
empresas_limpio <- empresas |>
  filter(!is.na(ventas_mm))

# Eliminar outliers extremos (errores evidentes)
empresas_limpio <- empresas |>
  filter(ventas_mm < 5000 | is.na(ventas_mm))  # Quitar ventas imposibles
```

Cuándo imputar

Imputar está bien cuando...

- Los NAs son **MAR** y tenés variables que explican el patrón.
- No querés perder observaciones (dataset chico).
- La imputación es razonable y la documentás.

```r
# Imputación simple: mediana (robusta a outliers)
mediana_ventas <- median(empresas$ventas_mm, na.rm = TRUE)

# Imputación por grupo (más sofisticada)
empresas_imputado <- empresas |>
  group_by(sector) |>
  mutate(ventas_imp = ifelse(is.na(ventas_mm),
                             median(ventas_mm, na.rm = TRUE),
                             ventas_mm)) |>
  ungroup()
```

Cuándo imputar (cont.)

Métodos de imputación comunes

- **Media/mediana**: simple, pero ignora relaciones entre variables.
- **Media/mediana por grupo**: mejor, captura diferencias entre categorías.
- **Modelo predictivo**: usar una regresión para predecir el valor faltante (más avanzado).
- **Imputación múltiple**: generar varias versiones del dataset con distintas imputaciones.

Regla

Si imputás más del 20-30% de una variable, probablemente esa variable **no sea confiable** para el análisis.

Imputación múltiple: la idea

¿Por qué no alcanza con imputar una sola vez?

Si reemplazo un NA por la mediana, estoy **inventando** un dato puntual. Eso subestima la variabilidad real: el análisis cree que tiene más certeza de la que tiene.

La solución: imputar varias veces

La **imputación múltiple** genera m versiones del dataset (típicamente 5-20), cada una con valores imputados ligeramente distintos. Luego:

1. Se corre el análisis en **cada** versión.
2. Se **combinan** los resultados usando reglas que incorporan la incertidumbre de la imputación (reglas de Rubin).

Resultado

Los intervalos de confianza son más honestos: reflejan que **no sabemos** cuál era el verdadero valor faltante.

Imputación múltiple: ejemplo conceptual

```r
# El paquete 'mice' es el estándar en R
library(mice)

# Paso 1: generar m=5 datasets imputados
imp <- mice(empresas, m = 5, method = "pmm", seed = 42)
# pmm = predictive mean matching (bueno para datos continuos)

# Paso 2: ajustar el modelo en cada dataset imputado
fit <- with(imp, lm(ventas_mm ~ empleados + antiguedad))

# Paso 3: combinar resultados (reglas de Rubin)
resultado <- pool(fit)
summary(resultado)
```

¿Cuándo vale la pena?

- Cuando los NAs son **MAR** y representan más del 5-10% de los datos.
- Cuando el análisis es inferencial (tests, intervalos de confianza).
- Para un TP o informe descriptivo, la imputación por grupo suele ser suficiente.

Cuándo mantener

Mantener está bien cuando...

- El outlier es un dato **genuinamente extremo** y es relevante.
- El NA es **informativo**: que falte el dato dice algo (MNAR).
- Se puede crear una variable indicadora: `tiene_dato = !is.na(x)`.

Cuándo mantener

```r
# Crear indicadora de missingness (útil para modelos)
empresas <- empresas |>
  mutate(ventas_reportadas = !is.na(ventas_mm))

# Winsorizar: no eliminar, sino recortar a los percentiles
empresas <- empresas |>
  mutate(ventas_wins = case_when(
    ventas_mm > quantile(ventas_mm, 0.99, na.rm = TRUE) ~
      quantile(ventas_mm, 0.99, na.rm = TRUE),
    ventas_mm < quantile(ventas_mm, 0.01, na.rm = TRUE) ~
      quantile(ventas_mm, 0.01, na.rm = TRUE),
    TRUE ~ ventas_mm
  ))
```

Winsorización: recortar sin eliminar

¿Qué es?

En lugar de **eliminar** los outliers, se **reemplazan** por el valor del percentil elegido (ej: 1 y 99, o 5 y 95). Así se conserva la observación pero se limita su influencia extrema.

Ventajas

- No se pierde ninguna observación (el n no cambia).
- Reduce el efecto de valores extremos en media, desvío y regresiones.
- Es transparente y fácil de documentar: "se winsorizó al percentil 1-99".

¿Cuándo preferirla sobre eliminar?

Cuando los valores extremos son **genuinos pero influyentes** (no errores de carga), y no querés perder información sobre esas observaciones en las demás variables.

Winsorización en R

```
# A tibble: 1 x 5
  media_orig media_wins sd_orig sd_wins     n
       <dbl>      <dbl>   <dbl>   <dbl> <int>
1       93.6       38.6    701.    170.   180
```

Resumen del framework

Situación	Eliminar	Imputar	Mantener
MCAR, pocos NAs	**Sí**	Puede	No necesario
MAR	Sesga	**Sí (por grupo)**	Evaluar
MNAR	Sesga más	Riesgoso	**Sí + indicadora**
Error de carga	**Sí**	Si se puede corregir	No
Outlier genuino	No	Winsorizar	**Sí**

Clave

Cualquier decisión que tomen debe estar **documentada y justificada**. Decir "eliminé los NAs" sin explicar por qué no es aceptable.

Evaluar el impacto: antes vs después

Principio

Toda decisión de limpieza (eliminar, imputar, winsorizar) cambia los datos. Hay que **medir y reportar** cuánto cambian las estadísticas clave para verificar que la decisión es razonable.

```r
# Función para comparar estadísticas descriptivas
comparar_stats <- function(original, modificado, nombre) {
  tibble(
    version  = c("Original", nombre),
    n        = c(length(original), length(modificado)),
    media    = round(c(mean(original), mean(modificado)), 1),
    mediana  = round(c(median(original), median(modificado)), 1),
    desvio   = round(c(sd(original), sd(modificado)), 1),
    p05      = round(c(quantile(original, .05), quantile(modificado, .05)), 1),
    p95      = round(c(quantile(original, .95), quantile(modificado, .95)), 1)
  )
}

v_orig  <- empresas$ventas_mm[!is.na(empresas$ventas_mm)]
v_wins  <- winsorizar(v_orig, 0.01, 0.99)
```

Evaluar el impacto: qué mirar

Señales de alerta

- La **media cambia mucho** pero la **mediana casi no**: los outliers estaban tirando la media. La decisión de limpiar probablemente fue correcta.
- El n **cae drásticamente**: estás perdiendo demasiadas observaciones. Reconsiderar el criterio o usar winsorización.
- El **desvío baja mucho**: ganás estabilidad pero podés estar ocultando variabilidad real.
- Las **conclusiones del análisis cambian**: correr el modelo con y sin limpieza. Si los resultados son muy distintos, reportar ambos.

Buena práctica

Incluir en el informe una tabla como la del slide anterior y una frase como: "Se eliminaron 5 observaciones (2.5%) identificadas como outliers por IQR. La media de ventas pasó de 85.2 a 42.1 MM; la mediana se mantuvo estable (12.3 vs 11.8 MM), lo cual confirma que los valores eliminados eran extremos atípicos."

Transformaciones de variables

¿Por qué transformar?

Motivación

Muchos métodos estadísticos funcionan mejor cuando las variables tienen ciertas propiedades: simetría, escala similar, linealidad. Las transformaciones nos ayudan a lograr eso.

Situaciones típicas

- Los ingresos tienen **cola derecha larga**: pocos valores muy altos tiran la media $\rightarrow$ transformación logarítmica.
- Queremos comparar variables en **distintas escalas** (ventas en millones vs empleados) $\rightarrow$ estandarización.
- Un modelo necesita variables entre **0 y 1** $\rightarrow$ normalización min-max.

Transformación logarítmica

¿Cuándo usarla?

Cuando la variable es **positiva** y tiene una **distribución asimétrica a la derecha** (cola larga). Muy común en economía: ingresos, PIB, precios, ventas.

$$x' = \log(x)$$

Cuidados

- El logaritmo de 0 es $-\infty$. Si hay ceros, usar $\log(x+1)$.
- El logaritmo de un número negativo no existe. Si hay negativos, log no sirve.
- Los coeficientes de una regresión con log se interpretan como **elasticidades** o cambios porcentuales (ventaja en economía).

Transformación logarítmica en R

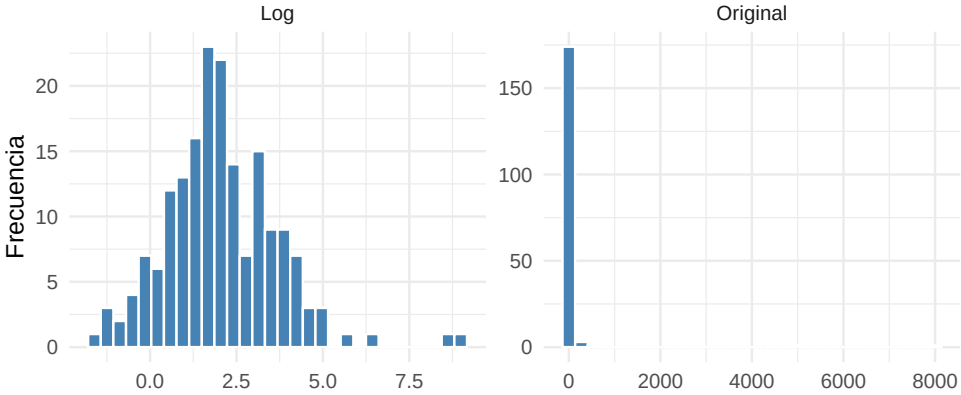

Estandarización (z-score)

¿Qué hace?

Transforma la variable para que tenga **media 0** y **desvío estándar 1**:

$$z_i = \frac{x_i - \bar{x}}{s}$$

El resultado indica cuántos desvíos estándar cada valor está de la media.

¿Cuándo usarla?

- Para **comparar** variables con distintas unidades (ventas vs empleados).
- En modelos donde las escalas importan (clustering, PCA, regularización).
- Para identificar valores extremos (z-score como detector de outliers).

Estandarización en R

```
# A tibble: 1 x 4
  media_ventas_z sd_ventas_z media_empl_z sd_empl_z
           <dbl>       <dbl>        <dbl>     <dbl>
1              0           1            0         1
```

Normalización min-max

¿Qué hace?

Escala la variable al rango $[0, 1]$:

$$x_i' = \frac{x_i - x_{min}}{x_{max} - x_{min}}$$

El mínimo se convierte en 0 y el máximo en 1.

¿Cuándo usarla?

- Cuando necesitás que todas las variables estén en el **mismo rango**.
- Algoritmos como redes neuronales o KNN son sensibles a la escala.
- Cuidado: es **muy sensible a outliers** (un valor extremo comprime el resto).

Normalización min-max en R

```
# A tibble: 1 x 4
  min_ventas_norm max_ventas_norm min_empleados_norm max_empleados_norm
            <dbl>           <dbl>               <dbl>               <dbl>
1               0               1                   0                   1
```

Comparación de transformaciones

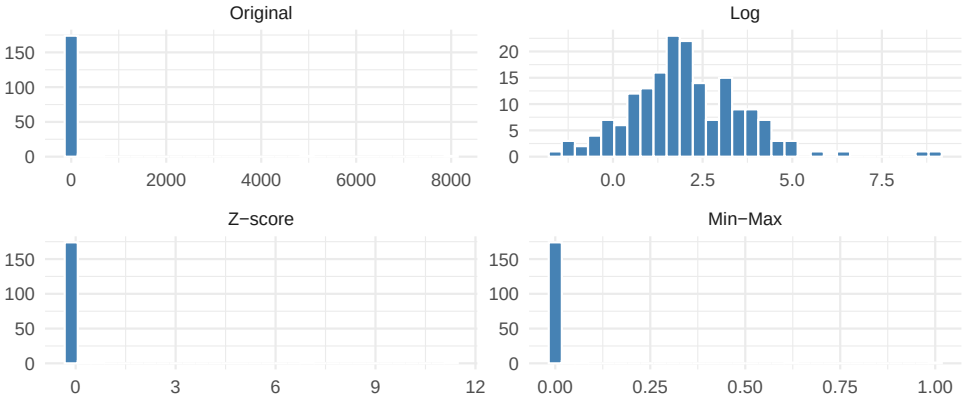

Resumen de transformaciones

Transformación	Fórmula	Cuándo usar	Cuidado
Logarítmica	$\log(x)$	Asimetría derecha, elasticidades	No acepta ≤ 0
Estandarización	$\frac{x-\bar{x}}{s}$	Comparar escalas, clustering	Sensible a outliers
Min-Max	$\frac{x-min}{max-min}$	Rango [0,1], redes neuronales	Muy sensible a outliers

Regla general

La transformación logarítmica cambia la **forma** de la distribución. La estandarización y min-max cambian la **escala** pero no la forma.

Justificación e impacto

Documentar las decisiones

¿Por qué documentar?

Todo cambio que hagamos a los datos (eliminar, imputar, transformar) debe quedar **registrado y justificado**. El análisis debe ser reproducible, incluyendo las decisiones de limpieza.

Qué documentar

- **Cuántos NAs** había por variable y qué porcentaje representan.
- **Qué tipo de missing** se diagnosticó (y con qué evidencia).
- **Qué criterio** se usó para detectar outliers y cuántos se encontraron.
- **Qué acción** se tomó (eliminar, imputar, winsorizar, mantener).
- **Qué transformaciones** se aplicaron y por qué.

Medir el impacto

Es importante comparar las estadísticas *antes y después* de las decisiones de limpieza:

```
# A tibble: 1 x 6
  media_orig mediana_orig sd_orig media_clean mediana_clean sd_clean
       <dbl>        <dbl>   <dbl>       <dbl>         <dbl>    <dbl>
1       93.6          6.7    701.         9.5           5.1     10.5
```

Medir el impacto (cont.)

Preguntas clave para evaluar el impacto

- ¿Cuántas observaciones perdí? ¿Qué porcentaje del total?
- ¿Cambió significativamente la media/mediana?
- ¿Se alteró la relación entre variables?
- Si repito el análisis con y sin limpieza, ¿cambian las conclusiones?

Buena práctica para el TP

Incluir una tabla comparativa "antes vs después" en el informe. Mostrar que las decisiones fueron razonadas y que se evaluó su efecto.