Clase 14: Regresión lineal

Modelo simple y múltiple | Dummies | Logaritmos | Supuestos | Errores robustos

Nicolás Sidicaro

Ciencia de Datos para Economía y Negocios | FCE-UBA

¿Por qué regresión lineal?

La pregunta central

¿Cómo se relacionan dos variables?

Idea

Dada una variable de interés Y (la que queremos explicar) y un conjunto de variables $X_1, X_2, \ldots, X_k$ (los *predictores*), buscamos describir esa relación con la **recta** (o hiperplano) que mejor ajuste a los datos.

Ejemplos económicos

- ¿Cuánto sube el **precio de un departamento** por cada m^2 adicional?
- ¿Cuál es el efecto de la **educación** sobre los **salarios**?
- ¿Cómo influye la **tasa de interés** en la **inversión**?

¿Por qué *lineal*?

Las virtudes de un modelo simple

- Es el modelo más **transparente**: cada coeficiente tiene una interpretación clara.
- Permite responder preguntas tanto **descriptivas** como **causales** (con identificación apropiada).
- Sus supuestos son explícitos y **contrastables**.
- Es la base sobre la que se construyen modelos más complejos.

Importante

Que el modelo sea *lineal en los parámetros* no quiere decir que la relación sea lineal en las variables. Vamos a ver que con **logaritmos** y **transformaciones** podemos capturar relaciones no lineales sin abandonar el marco MCO.

Hoja de ruta de la clase

1. **Modelo lineal simple**: `lm()`, `summary()` e interpretación.
2. **Regresión múltiple**: ceteris paribus y R^2 ajustado.
3. **Variables categóricas**: dummies y nivel de referencia.
4. **Logaritmos**: las cuatro formas funcionales y sus interpretaciones.
5. **Supuestos de Gauss-Markov**: cuándo MCO es BLUE.
6. **Heteroscedasticidad**: detección y errores robustos de White.

Dataset: inmuebles en CABA

Vamos a trabajar con un dataset **simulado** de propiedades en Capital Federal:

```r
set.seed(42)
n <- 500
inmuebles <- tibble(
  id          = 1:n,
  m2          = round(rlnorm(n, meanlog = 4.2, sdlog = 0.5)),
  ambientes   = sample(1:5, n, replace = TRUE,
                       prob = c(0.15, 0.30, 0.30, 0.15, 0.10)),
  antiguedad = sample(0:80, n, replace = TRUE),
  barrio      = sample(c("Palermo", "Belgrano", "Caballito",
                         "Almagro", "Flores"), n, replace = TRUE,
                       prob = c(0.25, 0.20, 0.20, 0.20, 0.15)),
  tipo        = sample(c("Departamento", "Casa", "PH"), n, replace = TRUE,
                       prob = c(0.70, 0.15, 0.15))
)

precio_m2   <- c(Palermo = 3500, Belgrano = 3200, Caballito = 2400,
                 Almagro = 2200, Flores = 1900)
factor_tipo <- c(Departamento = 1.0, Casa = 1.15, PH = 0.90)
```

Una mirada a los datos

```
inmuebles |> slice_head(n = 6) |> kable()
```

id	m2	ambientes	antiguedad	barrio	tipo	precio_usd
1	132	1	77	Flores	Departamento	149903
2	50	2	1	Caballito	Departamento	95194
3	80	1	13	Almagro	Departamento	154410
4	92	3	55	Palermo	Departamento	180838
5	82	3	73	Caballito	Departamento	147109
6	63	2	65	Caballito	Departamento	96144

n	m2_mediano	precio_mediano	precio_min	precio_max
500	65.5	140263	26339	775961

Modelo lineal simple

La idea geométrica

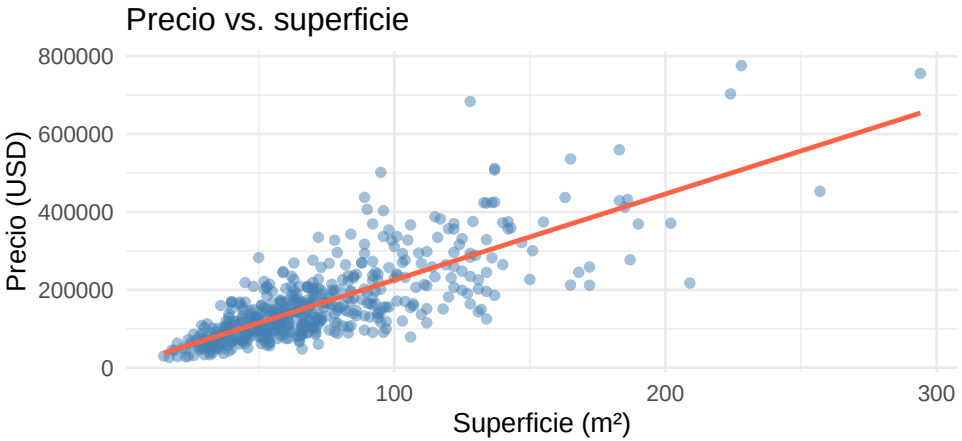

¿Qué hace la regresión simple?

Ajusta la **recta** que mejor describe la relación entre dos variables: la pendiente cuantifica cuánto cambia Y ante un cambio unitario en X.

La forma matemática

Modelo poblacional

$$Y_i = \beta_0 + \beta_1 X_i + u_i$$

- β_0: **intercepto** (valor de Y cuando $X = 0$).
- β_1: **pendiente** (cambio en Y ante un cambio unitario en X).
- u_i: **término de error** (todo lo que afecta a Y y no está en el modelo).

Modelo estimado

$$\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 X_i$$

A partir de los datos, estimamos $\hat{\beta}_0$ y $\hat{\beta}_1$. La diferencia $\hat{u}_i = Y_i - \hat{Y}_i$ es el **residuo**.

Mínimos Cuadrados Ordinarios (MCO)

El criterio

MCO elige $\hat{\beta}_0$ y $\hat{\beta}_1$ que **minimizan la suma de residuos al cuadrado**:

$$\min_{\beta_0,\beta_1} \sum_{i=1}^{n} (Y_i - \beta_0 - \beta_1 X_i)^2$$

¿Por qué al cuadrado?

- Penaliza más los errores grandes que los chicos.
- Trata por igual desviaciones positivas y negativas.
- Permite obtener una solución **cerrada** (fórmula explícita) y propiedades estadísticas conocidas.

lm() en R

La función `lm()` (*linear model*) ajusta el modelo:

```
modelo_simple <- lm(precio_usd ~ m2, data = inmuebles)
modelo_simple
```

```
Call:
lm(formula = precio_usd ~ m2, data = inmuebles)

Coefficients:
(Intercept)           m2
       4372         2210
```

Sintaxis: la fórmula

`precio_usd ~ m2` se lee *"precio en función de m2"*. El intercepto se incluye automáticamente. Para omitirlo: `precio_usd ~ m2 - 1`.

summary(): el output completo

```r
summary(modelo_simple)
```

```
Call:
lm(formula = precio_usd ~ m2, data = inmuebles)

Residuals:
    Min      1Q  Median      3Q     Max 
-248830  -38153   -4521   30240  396529 

Coefficients:
            Estimate Std. Error t value            Pr(>|t|)    
(Intercept)  4372.39    6638.55   0.659               0.51    
m2           2209.87      79.74  27.712 <0.0000000000000002 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 68180 on 498 degrees of freedom
Multiple R-squared:  0.6066,	Adjusted R-squared:  0.6058 
F-statistic: 767.9 on 1 and 498 DF,  p-value: < 0.0000000000000022
```

Cómo leer el `summary()`

Sección	Qué dice
`Call`	La fórmula que se estimó.
`Residuals`	Distribución de los residuos (mín, Q1, mediana, Q3, máx).
`Estimate`	El valor estimado de cada coeficiente.
`Std. Error`	Error estándar del estimador.
`t value`	Estadístico $t = \hat{\beta}/SE(\hat{\beta})$.
`Pr(>|t|)`	p-valor del test $H_0 : \beta = 0$.
`Multiple R-squared`	Proporción de la varianza de Y explicada por el modelo.
`F-statistic`	Test de significancia conjunta del modelo.

Las estrellas

$*** = p < 0.001$, $** = p < 0.01$, $* = p < 0.05$. Indican significancia estadística, **no** relevancia económica ni causalidad.

Interpretación de los coeficientes

Modelo: $\widehat{precio} = \hat{\beta}_0 + \hat{\beta}_1 \cdot m^2$

- $\hat{\beta}_0$ (**intercepto**): precio estimado cuando `m2 = 0`. A menudo carece de sentido económico (un departamento de 0 m^2 no existe), pero es necesario para que la recta ajuste bien.
- $\hat{\beta}_1$ (**pendiente**): cambio promedio en el precio (USD) ante un m^2 adicional.

Lectura típica

"Por cada metro cuadrado adicional, el precio aumenta en promedio $\hat{\beta}_1$ dólares, manteniendo todo lo demás constante."

R^2: bondad de ajuste

Definición

$$R^2 = \frac{SC_{\text{exp}}}{SC_{\text{tot}}} = 1 - \frac{SC_{\text{res}}}{SC_{\text{tot}}}$$

Donde:

- $SC_{\text{tot}} = \sum (Y_i - \bar{Y})^2$: variación total de Y.
- $SC_{\text{res}} = \sum \hat{u}_i^2$: variación no explicada (residuos).
- $SC_{\text{exp}} = SC_{\text{tot}} - SC_{\text{res}}$: variación explicada por el modelo.

Interpretación

$R^2 = 0.65$ significa que el modelo **explica el 65%** de la variabilidad observada en Y. Va siempre entre 0 y 1.

Cuidados con el R^2

Lo que el R^2 NO dice

- **No** dice que el modelo sea "correcto": un R^2 alto puede esconder relaciones espurias.
- **No** dice que las predicciones sean buenas fuera de muestra.
- **No** permite comparar modelos con distintos Y (por ejemplo `precio` vs. `log(precio)`).
- **Aumenta siempre** al agregar variables, incluso variables irrelevantes (por eso existe el R^2 ajustado).

Regla práctica

Un R^2 "bueno" depende del contexto. En finanzas con datos de alta frecuencia, $R^2 = 0.05$ puede ser excelente. En datos cross-section bien especificados, esperamos 0.3–0.7.

Visualizando el ajuste

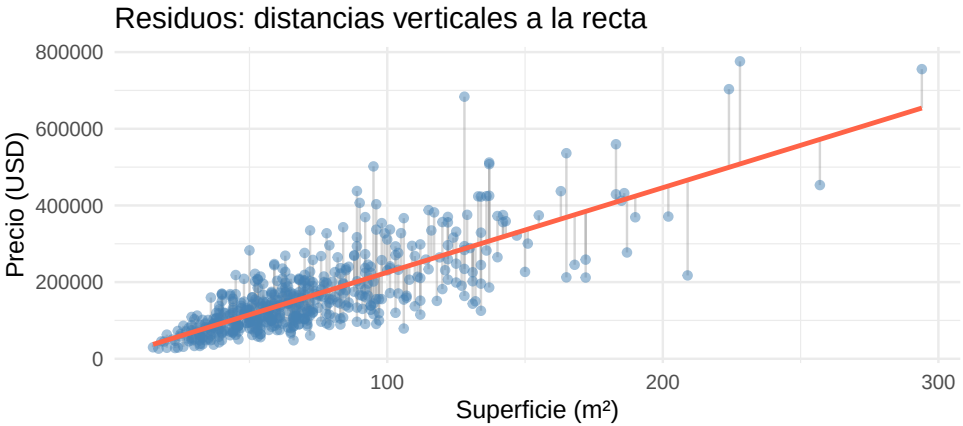

Regresión múltiple

¿Por qué más variables?

Motivación

Una sola variable rara vez explica bien Y. El precio de un inmueble depende de los m^2, pero también del **barrio**, el **tipo**, la **antigüedad**...

Modelo lineal múltiple

$$Y_i = \beta_0 + \beta_1 X_{1i} + \beta_2 X_{2i} + \cdots + \beta_k X_{ki} + u_i$$

- Cada β_j es el efecto **parcial** de X_j sobre Y.
- Se interpretan *ceteris paribus*: manteniendo las demás variables constantes.

La idea de *ceteris paribus*

El gran cambio

En la regresión simple, $\hat{\beta}_1$ mezcla el efecto directo de X con el de cualquier variable correlacionada con X. En la regresión múltiple, $\hat{\beta}_j$ aísla el efecto de X_j **controlando** por las demás.

Ejemplo concreto

- Modelo simple: "cada m^2 extra suma USD 5.000 al precio".
- Modelo múltiple: "cada m^2 extra suma USD 3.500 al precio, **una vez que controlamos por barrio y tipo de propiedad**".

La diferencia surge porque las propiedades grandes tienden a estar en barrios más caros: parte del efecto "m^2" en el modelo simple era en realidad efecto "barrio".

Múltiple en R

```r
modelo_mult <- lm(precio_usd ~ m2 + ambientes + antiguedad,
                  data = inmuebles)
summary(modelo_mult)$coefficients |> round(2)
```

```
            Estimate Std. Error t value Pr(>|t|)
(Intercept) 37092.75   10146.06    3.66     0.00
m2           2228.03      75.14   29.65     0.00
ambientes    1775.52    2494.56    0.71     0.48
antiguedad   -977.23     120.82   -8.09     0.00
```

Interpretación

"Por cada m^2 adicional, el precio aumenta en promedio USD $\hat{\beta}_{m2}$, manteniendo *constantes* los ambientes y la antigüedad."

R^2 ajustado

El problema

El R^2 aumenta **siempre** al agregar variables, aunque no aporten nada. No sirve para elegir entre modelos con distinta cantidad de regresores.

La corrección

$$R^2_{\text{aj}} = 1 - \frac{SC_{\text{res}}/(n-k-1)}{SC_{\text{tot}}/(n-1)}$$

Penaliza por agregar variables: solo sube si la nueva variable mejora el ajuste **más** de lo que cuesta perder un grado de libertad.

Regla

Para comparar modelos con distinto número de variables, mirar siempre R^2_{aj}, no R^2.

AIC y BIC: criterios de información

La idea

Combinan el **ajuste** del modelo (qué tan bien replica los datos, vía la log-verosimilitud) con una **penalización por complejidad** (cantidad de parámetros). **Menor es mejor**.

Las fórmulas

$$\text{AIC} = -2\log\mathcal{L} + 2k \qquad \text{BIC} = -2\log\mathcal{L} + k\log(n)$$

$\log\mathcal{L}$ es la log-verosimilitud, k el número de parámetros, n el tamaño de la muestra.

En la práctica

- Sirven para comparar modelos **no anidados** (algo que el test F no puede).
- BIC penaliza más fuerte que AIC ($k\log n > 2k$ para $n > 7$): tiende a elegir modelos más **parsimoniosos**.
- Solo se comparan sobre la **misma variable dependiente**: no podemos usar AIC para comparar un modelo en `precio` contra uno en `log(precio)`.
- Los valores absolutos no significan nada: importa la **diferencia** entre modelos.

Comparando modelos

```r
comparar <- bind_rows(
  glance(modelo_simple) |> mutate(modelo = "Simple (m2)"),
  glance(modelo_mult)   |> mutate(modelo = "Múltiple (m2 + amb + ant)")
) |>
  select(modelo, r.squared, adj.r.squared, sigma, AIC, BIC) |>
  mutate(across(where(is.numeric), \(x) round(x, 3)))

comparar |> kable()
```

modelo	r.squared	adj.r.squared	sigma	AIC	BIC
Simple (m2)	0.607	0.606	68184.40	12552.91	12565.55
Múltiple (m2 + amb + ant)	0.652	0.650	64216.22	12494.93	12516.01

Lectura

El modelo múltiple tiene mayor R^2 y R^2 ajustado, y menor AIC/BIC: las variables agregadas aportan información genuina.

Multicolinealidad: una nota breve

¿Qué es?

Cuando dos o más predictores están **altamente correlacionados**, MCO puede estimar coeficientes con errores estándar enormes (alta varianza). Es difícil "aislar" el efecto de cada uno.

Síntomas

- Coeficientes "raros" (signo opuesto al esperado).
- Errores estándar muy grandes pese a un R^2 alto.
- Los coeficientes cambian mucho al agregar/quitar variables.

Diagnóstico simple

Mirar la **matriz de correlaciones** entre predictores. Para diagnóstico formal: **VIF** (Variance Inflation Factor) con `car::vif()`.

Variables categóricas (dummies)

El problema

¿Cómo meto "barrio" en una regresión?

Una variable como `barrio` no es un número: no podemos escribir $\beta \cdot$ Palermo. Necesitamos transformarla en **indicadoras numéricas**.

La idea de la dummy

Para una variable categórica con k niveles, creamos $k-1$ variables **dummy** (0/1):

- Una de las categorías se elige como **nivel de referencia** (no tiene dummy).
- Cada dummy vale 1 si la observación pertenece a esa categoría, 0 si no.

Codificación dummy: el ejemplo

barrio	Belgrano	Caballito	Palermo
Almagro (ref.)	0	0	0
Belgrano	1	0	0
Caballito	0	1	0
Palermo	0	0	1

¿Por qué $k-1$ y no k dummies?

Si incluyéramos una dummy por cada categoría **junto con** el intercepto, las dummies sumarían exactamente 1 para toda observación: habría **colinealidad perfecta** con el intercepto. Es la llamada "trampa de la dummy".

En R: `factor()` y nivel base

R hace todo esto automáticamente cuando incluís una variable de tipo `factor` en `lm()`:

```
inmuebles <- inmuebles |>
  mutate(barrio = factor(barrio),
         tipo   = factor(tipo))

# Ver el nivel base (alfabético por defecto)
levels(inmuebles$barrio)
```

```
[1] "Almagro"   "Belgrano"  "Caballito" "Flores"    "Palermo"
```

```
levels(inmuebles$tipo)
```

```
[1] "Casa"         "Departamento" "PH"
```

El nivel base por defecto

R toma el primer nivel **alfabéticamente** como referencia. En nuestro caso: "Almagro" para barrio y "Casa" para tipo. Esto es arbitrario y conviene cambiarlo según el contexto.

Cambiando el nivel de referencia

```r
inmuebles <- inmuebles |>
  mutate(
    barrio = relevel(barrio, ref = "Caballito"),
    tipo   = relevel(tipo,   ref = "Departamento")
  )

levels(inmuebles$barrio)
```

```
[1] "Caballito" "Almagro"   "Belgrano"  "Flores"    "Palermo"
```

```r
levels(inmuebles$tipo)
```

```
[1] "Departamento" "Casa"         "PH"
```

¿Por qué Caballito y Departamento?

- **Caballito**: barrio "promedio" geográfica y económicamente: facilita interpretar los demás como "premium" o "descuento".
- **Departamento**: tipo más frecuente, referencia natural para Casa y PH.

Regresión con barrio

```r
modelo_barrio <- lm(precio_usd ~ m2 + barrio, data = inmuebles)
summary(modelo_barrio)$coefficients |> round(1)
```

```
               Estimate Std. Error t value Pr(>|t|)
(Intercept)     -9946.4     7352.0    -1.4      0.2
m2               2242.8       67.7    33.1      0.0
barrioAlmagro  -22388.6     8114.6    -2.8      0.0
barrioBelgrano  43077.7     8153.9     5.3      0.0
barrioFlores   -35739.4     8573.6    -4.2      0.0
barrioPalermo   59085.8     7822.3     7.6      0.0
```

Cómo se lee

Cada coeficiente de barrio mide la diferencia promedio respecto a **Caballito** (la referencia), manteniendo m^2 constante.

Interpretación: ¿qué nos dicen los coeficientes?

Lectura del modelo

- `(Intercept)`: precio estimado de un inmueble de 0 m^2 en Caballito (poco sentido económico solo).
- `m2`: cada m^2 adicional suma USD $\hat{\beta}_{m2}$, controlando por barrio.
- `barrioPalermo`: una propiedad en Palermo cuesta en promedio USD $\hat{\beta}_{Palermo}$ **más** que una equivalente en Caballito (mismo m^2).
- `barrioFlores`: si el coeficiente es **negativo**, propiedades en Flores cuestan menos que las de Caballito a igual superficie.

Visualmente

Los coeficientes de las dummies son "corrimientos verticales" de la recta de regresión: distintas intercepciones, misma pendiente.

No significatividad de dummies

Cuando un coeficiente *no* es significativo

Si la dummy de una categoría (por ejemplo, `barrioBelgrano`) tiene un p-valor **alto** ($p > 0.05$), **no** concluimos que "el barrio no influye en el precio". Lo que decimos es que **no podemos rechazar** que esa categoría sea **equivalente al nivel de referencia** (Caballito) en su efecto sobre el precio, controlando por las demás variables.

Visualización: rectas paralelas por barrio

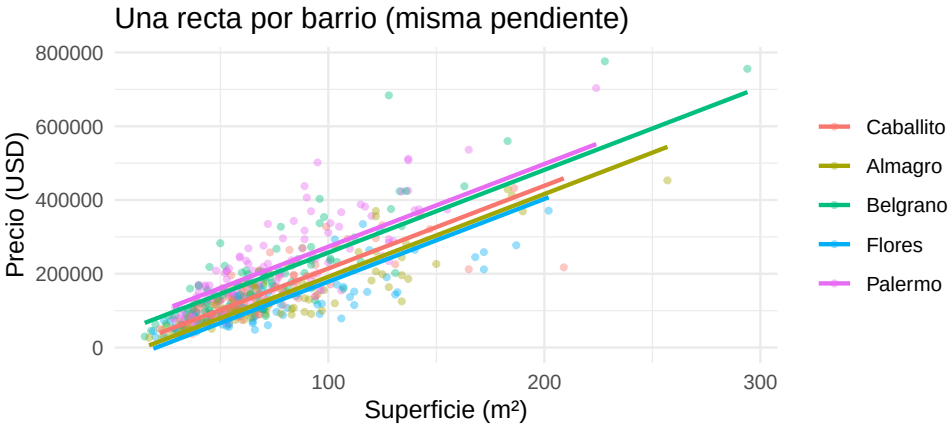

Múltiples categóricas a la vez

```r
modelo_completo <- lm(precio_usd ~ m2 + ambientes + antiguedad +
                                   barrio + tipo,
                      data = inmuebles)
summary(modelo_completo)$coefficients |> round(1)
```

```
               Estimate Std. Error t value Pr(>|t|)
(Intercept)     32944.8     9230.8     3.6      0.0
m2               2259.9       60.4    37.4      0.0
ambientes       -1024.6     2005.8    -0.5      0.6
antiguedad      -1030.9       96.8   -10.6      0.0
barrioAlmagro  -22287.9     7230.9    -3.1      0.0
barrioBelgrano  42896.4     7286.0     5.9      0.0
barrioFlores   -36867.6     7649.1    -4.8      0.0
barrioPalermo   62435.4     6978.1     8.9      0.0
tipoCasa        17272.3     7020.9     2.5      0.0
tipoPH         -15644.8     5887.0    -2.7      0.0
```

Interacciones: una nota al pie

¿Y si la pendiente cambia con la categoría?

Hasta acá asumimos que el efecto del m^2 sobre el precio es **el mismo en todos los barrios**: las dummies solo desplazan la recta hacia arriba o abajo. Una **interacción** permite que la pendiente *también* dependa del grupo:

$$\widehat{precio} = \beta_0 + \beta_1\, m^2 + \beta_2\, \text{Palermo} + \beta_3\, (m^2 \times \text{Palermo}) + \cdots$$

En R: simplemente $*$ en la fórmula

`lm(precio_usd ~ m2 * barrio, data = inmuebles)` Esto incluye los efectos principales y todas las interacciones automáticamente.

No entramos en detalle

Las interacciones permiten capturar **efectos heterogéneos** (un mismo cambio en X impacta distinto en grupos diferentes), pero su interpretación es más sutil. Las dejamos para más adelante en el curso.

Variables categóricas: resumen

Lo esencial

- Variables categóricas se codifican como $k-1$ **dummies** más un nivel de referencia.
- En R: convertir a `factor()`, eventualmente `relevel()` para fijar la referencia.
- Cada coeficiente mide la diferencia promedio respecto al nivel de referencia.
- **No interpretar** el intercepto solo: combina la base de todas las categóricas.

Significancia de la variable completa

El test t individual de *una* dummy no nos dice si la variable categórica completa es relevante. Para eso, usamos un **test F** con `anova()` comparando modelos con y sin la variable.

Modelos con logaritmo

¿Por qué transformar con log?

Tres razones

1. **Forma de la distribución**: variables como ingresos, ventas o precios suelen tener **cola derecha larga**. El log las simetriza.
2. **Heteroscedasticidad**: si la varianza crece con el nivel, el log la estabiliza (recordemos clase 12).
3. **Interpretación económica**: los coeficientes con log se leen como **cambios porcentuales** y **elasticidades**, conceptos centrales en economía.

Recordatorio

$\log(x)$ requiere $x > 0$. Para variables con ceros, se usa $\log(x + 1)$ con cuidado interpretativo.

Las cuatro formas funcionales

Forma	**Modelo**	**Interpretación de β_1**
Nivel-Nivel	$Y = \beta_0 + \beta_1 X$	$\Delta X = 1 \Rightarrow \Delta Y = \beta_1$ unidades
Log-Nivel	$\log(Y) = \beta_0 + \beta_1 X$	$\Delta X = 1 \Rightarrow \Delta\% Y \approx 100\beta_1\,\%$
Nivel-Log	$Y = \beta_0 + \beta_1 \log(X)$	$\Delta\% X = 1 \Rightarrow \Delta Y \approx \beta_1/100$ unidades
Log-Log	$\log(Y) = \beta_0 + \beta_1 \log(X)$	$\Delta\% X = 1\% \Rightarrow \Delta\% Y \approx \beta_1\,\%$ (**elasticidad**)

Aproximaciones

Las interpretaciones porcentuales son **aproximadas** y funcionan bien para cambios chicos (menores a 10%). Para cambios grandes, la fórmula exacta es $100 \cdot (e^{\beta_1} - 1)\,\%$.

Por qué log-log da elasticidad

Demostración rápida

Partiendo de $\log(Y) = \beta_0 + \beta_1 \log(X)$, derivamos respecto a X:

$$\frac{1}{Y}\frac{dY}{dX} = \beta_1 \cdot \frac{1}{X} \quad \Rightarrow \quad \beta_1 = \frac{dY/Y}{dX/X} = \frac{\Delta\% Y}{\Delta\% X}$$

Por construcción, β_1 es la **elasticidad** de Y respecto a X.

Lectura típica

Si en `log(precio) ~ log(m2)` obtenemos $\hat{\beta}_1 = 0.92$, decimos: *"un aumento del 1% en la superficie está asociado a un aumento del 0.92% en el precio"*.

Comparación gráfica: nivel vs log-log

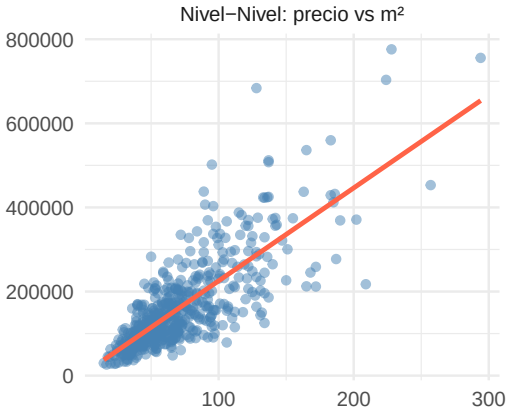

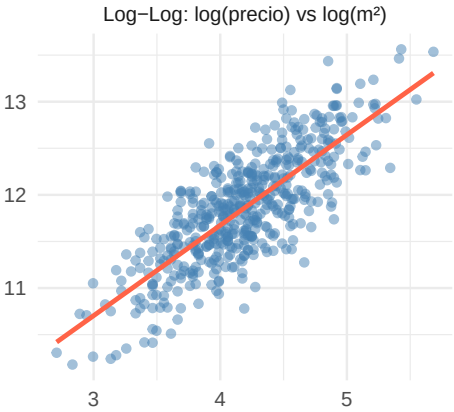

Lo que se ve

La forma **log-log** linealiza la relación y **estabiliza la varianza**: la nube se ve más uniforme.

Modelo log-log en R

```r
modelo_log <- lm(log(precio_usd) ~ log(m2) + ambientes + antiguedad +
                                   barrio + tipo,
                 data = inmuebles)
summary(modelo_log)$coefficients |> round(3)
```

	Estimate	Std. Error	t value	Pr(>|t|)
(Intercept)	7.937	0.102	77.628	0.000
log(m2)	0.993	0.023	43.378	0.000
ambientes	-0.015	0.010	-1.561	0.119
antiguedad	-0.006	0.000	-13.048	0.000
barrioAlmagro	-0.158	0.035	-4.551	0.000
barrioBelgrano	0.230	0.035	6.552	0.000
barrioFlores	-0.248	0.037	-6.735	0.000
barrioPalermo	0.338	0.034	10.081	0.000
tipoCasa	0.131	0.034	3.877	0.000
tipoPH	-0.119	0.028	-4.214	0.000

Interpretación del modelo log-log

Lectura coeficiente por coeficiente

- `log(m2)`: **elasticidad** del precio respecto a m². Si $\hat{\beta} = 0.95$: 1% más de superficie $\Rightarrow$ 0.95% más de precio.
- `ambientes`: aumento porcentual del precio por cada ambiente extra (es *nivel*, no log). Si $\hat{\beta} = 0.04$: un ambiente más $\approx$ 4% más de precio.
- `antiguedad`: $\hat{\beta} \cdot 100\%$ de cambio por año. Si $\hat{\beta} = -0.005$: cada año de antigüedad reduce $\approx$ 0.5% el precio.
- `barrioPalermo`: si $\hat{\beta} = 0.38$: estar en Palermo (vs Caballito) implica $\approx$ 38% (más exacto: $e^{0.38} - 1 = 46\%$) de premium.

Cuadro resumen rápido

Y	**X**	$\hat{\beta}$ **se lee como...**
nivel	nivel	efecto absoluto en unidades de Y
log	nivel	semielasticidad (% de Y por unidad de X)
nivel	log	efecto absoluto por % de X
log	log	elasticidad (% de Y por % de X)

Regla mental

- "log" del lado del Y $\Rightarrow$ el efecto se lee en **porcentaje de** Y.
- "log" del lado del X $\Rightarrow$ el cambio en X se piensa en **porcentaje**.

Logaritmo: ventajas en economía

Por qué a los economistas nos encantan los logs

- Las **elasticidades** son invariantes a la unidad de medida (USD vs ARS, m^2 vs ft^2).
- Las relaciones porcentuales son más estables a lo largo del tiempo y entre países.
- Funciones de producción Cobb-Douglas, demanda con elasticidad constante, ecuaciones de Mincer... todas son **lineales en logaritmos**.

Supuestos de Gauss-Markov

¿Por qué supuestos?

La pregunta

MCO **siempre** produce estimaciones (es solo álgebra). La pregunta es: ¿**cuándo** esas estimaciones son "buenas"?

Buenas en qué sentido

- **Insesgadas**: $E[\hat{\beta}] = \beta$ (en promedio dan en el clavo).
- **Consistentes**: con más datos, $\hat{\beta}$ converge al verdadero β.
- **Eficientes**: tienen la **menor varianza** entre los estimadores lineales insesgados.

Teorema de Gauss-Markov

Bajo los supuestos que veremos, MCO es **BLUE**: *Best Linear Unbiased Estimator*.

Los cinco supuestos

Supuesto	Nombre	Significado
GM1	Linealidad en parámetros	$Y = \beta_0 + \beta_1 X_1 + \cdots + \beta_k X_k + u$
GM2	Muestreo aleatorio	Las observaciones son una muestra i.i.d. de la población
GM3	No multicolinealidad perfecta	Ningún predictor es combinación lineal exacta de otros
GM4	Exogeneidad	$E[u \mid X_1, \ldots, X_k] = 0$: el error no se relaciona con los predictores
GM5	Homoscedasticidad	$\mathrm{Var}(u \mid X) = \sigma^2$: varianza constante del error

Bonus: GM6 — Normalidad

Necesario solo para que los tests t y F sean exactos en muestras chicas. En muestras grandes, el TCL nos protege.

GM4: Exogeneidad — el supuesto crítico

¿Qué dice?

$E[u \mid X] = 0$: una vez que conocemos los X, el "error" (lo no observado que afecta a Y) tiene media cero. **No hay correlación** entre los predictores y los factores omitidos.

Cuándo falla — y arruina todo

- **Variables omitidas relevantes**: si omito el barrio y el barrio influye en el precio Y se correlaciona con m^2, el coeficiente de m^2 está **sesgado**.
- **Causalidad inversa**: si Y afecta a X (ej.: el ingreso afecta a la educación, no solo al revés).
- **Error de medición** en los predictores.

Consecuencia

Si falla GM4, MCO da estimaciones **sesgadas e inconsistentes**. Ningún truco estadístico (errores robustos, más datos) lo arregla. Hay que repensar el modelo o usar técnicas de identificación causal (variables instrumentales, DID, RDD...).

GM5: Homoscedasticidad

¿Qué dice?

$\mathrm{Var}(u \mid X) = \sigma^2$: la varianza del error es **la misma** para todos los valores de X. La dispersión de los residuos no depende del nivel del predictor.

Cuándo falla

- Variables "de tamaño" (ventas, precios): la varianza tiende a crecer con el nivel.
- Datos con observaciones agregadas a distintos niveles (provincia vs país).
- Cualquier vez que el "ruido" se escala con el "señal".

Buena noticia

Si falla **solo** GM5 (heteroscedasticidad), MCO sigue siendo **insesgado y consistente**. Lo único que se rompe es la fórmula de los errores estándar. Esto se arregla con **errores robustos**.

Resumen: ¿qué pasa si falla cada supuesto?

Falla	Consecuencia	Solución
GM1 (linealidad)	Mala especificación	Transformar variables (logs, polinomios), interacciones
GM2 (muestreo)	Sesgo de selección	Diseño muestral, Heckman
GM3 (multicol.)	Errores estándar enormes	Quitar variables redundantes, regularización
GM4 (exogeneidad)	**Sesgo**: nada lo arregla con MCO	VI, panel, experimentos, DID, RDD
GM5 (homoscedast.)	SE incorrectos, tests inválidos	**Errores robustos de White** (esta clase)

Heteroscedasticidad y errores robustos

El problema en imágenes

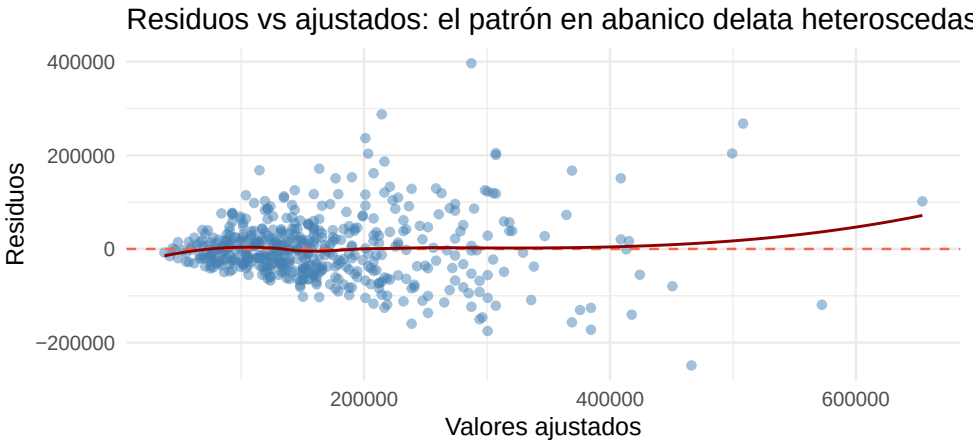

¿Por qué importa?

Las consecuencias

Bajo heteroscedasticidad:

1. Los coeficientes $\hat{\beta}$ siguen siendo **insesgados y consistentes**.
2. Pero los **errores estándar** reportados por R son **incorrectos**.
3. Por lo tanto, los **tests t**, los **p-valores** y los **intervalos de confianza** son **inválidos**.

En la práctica

Podés concluir que una variable es "significativa" cuando no lo es (o viceversa). Las "estrellas" del summary mienten.

Detección visual

Gráfico clave: residuos vs valores ajustados

- Si la varianza es constante: la nube se ve como una **banda horizontal** de ancho parejo.
- Si hay heteroscedasticidad: aparece un **abanico** (la dispersión crece o decrece con el nivel).

En R, una sola línea

`plot(modelo, which = 1)` grafica residuos vs ajustados con suavizado.

Test formal: Breusch-Pagan

```r
library(lmtest)

bptest(modelo_lin)
```

```
    studentized Breusch-Pagan test

data:  modelo_lin
BP = 82.455, df = 1, p-value < 0.00000000000000022
```

Cómo se lee

- H_0: **homoscedasticidad** (varianza constante).
- H_1: heteroscedasticidad.
- Si $p < 0.05$: rechazamos H_0, hay evidencia de heteroscedasticidad.

La idea de los errores robustos de White

El problema con la fórmula clásica

La varianza estándar de $\hat{\beta}$ asume homoscedasticidad:

$$\text{Var}(\hat{\beta}) = \sigma^2 (X'X)^{-1}$$

Con un único σ^2 común a todas las observaciones.

La corrección de White (1980) - Matriz sandwich

Reemplaza σ^2 por una estimación que **permite varianza distinta en cada observación**:

$$\text{Var}_{\text{HC}}(\hat{\beta}) = (X'X)^{-1} \left(\sum_i \hat{u}_i^2 \, x_i x_i' \right) (X'X)^{-1}$$

No hace falta saber la fórmula de memoria: alcanza con entender que los errores robustos **no asumen homoscedasticidad**, y por eso son válidos cuando ella falla.

En R: sandwich + lmtest

```r
library(sandwich)
library(lmtest)

# Errores estándar clásicos (asumen homoscedasticidad)
coeftest(modelo_lin)
```

```
t test of coefficients:

            Estimate Std. Error t value            Pr(>|t|)
(Intercept) 4372.387   6638.551  0.6586              0.5104
m2          2209.870     79.745 27.7119 <0.0000000000000002 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

En R

```r
# Errores robustos de White (HC1, el default de Stata)
coeftest(modelo_lin, vcov = vcovHC(modelo_lin, type = "HC1"))
```

```
t test of coefficients:

            Estimate Std. Error t value            Pr(>|t|)
(Intercept)  4372.39    8145.69  0.5368              0.5917
m2           2209.87     129.66 17.0430 <0.0000000000000002 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

Variantes de errores robustos

Tipo	Descripción
HC0	White original (1980); sesgado en muestras chicas.
HC1	HC0 con corrección por grados de libertad; **default de Stata**.
HC2	Corrige por leverage de cada observación.
HC3	Aproxima a jackknife; conservador, recomendado para muestras chicas ($<$ 250).

Recomendación práctica

- Muestra grande ($n > 250$): **HC1** (compatibilidad con literatura).
- Muestra chica: **HC3** (más conservador).
- En la duda: HC3.

Comparación: clásicos vs robustos

```r
clasicos <- coeftest(modelo_lin)
robustos <- coeftest(modelo_lin, vcov = vcovHC(modelo_lin, type = "HC1"))

tibble(
  Coeficiente = rownames(clasicos),
  Estimate    = round(clasicos[, "Estimate"], 2),
  SE_clasico  = round(clasicos[, "Std. Error"], 2),
  SE_robusto  = round(robustos[, "Std. Error"], 2),
  Ratio       = round(robustos[, "Std. Error"] / clasicos[, "Std. Error"], 2)
) |> kable()
```

Coeficiente	Estimate	SE_clasico	SE_robusto	Ratio
(Intercept)	4372.39	6638.55	8145.69	1.23
m2	2209.87	79.74	129.66	1.63

Lectura

Los $\hat{\beta}$ son idénticos (MCO no cambia). Lo que cambian son los errores estándar

Alternativa: `estimatr::lm_robust()`

Para quienes prefieren una sola llamada:

```r
library(estimatr)

modelo_robusto <- lm_robust(precio_usd ~ m2 + barrio + tipo,
                            data = inmuebles,
                            se_type = "HC1")
summary(modelo_robusto)
```

Ventajas de `lm_robust()`

- Una sola línea: estima y reporta SE robustos directamente.
- Soporta clustering: `clusters = barrio` para errores agrupados.
- Compatible con `broom::tidy()` para integrar con tidyverse.

¿Cuándo aplicar errores robustos?

Recomendación práctica de Angrist y Pischke

"Use heteroskedasticity-robust standard errors as a matter of course".
usalos **siempre** en datos de corte transversal. Si no hay heteroscedasticidad, los SE robustos coinciden con los clásicos. Si la hay, te salvaron de inferencia inválida.

Excepción

En **muestras chicas** ($n < 50$), los SE robustos pueden ser inestables: revisar HC3 o considerar bootstrap.

Cierre

Flujo de trabajo recomendado

1. **Explorar** la relación entre Y y los predictores con scatterplots.
2. **Plantear** el modelo: ¿lineal en niveles, en logs, con interacciones?
3. **Estimar** con `lm()` y leer `summary()`.
4. **Diagnosticar**: residuos vs ajustados, normalidad, heteroscedasticidad.
5. **Corregir**: si hay heteroscedasticidad, usar errores robustos.
6. **Interpretar**: coeficientes en su escala correcta; nivel, log o porcentaje.
7. **Comparar** modelos con R^2 ajustado, AIC, BIC y criterio económico.
8. **Reportar** con honestidad: limitaciones, supuestos cuestionables, alcance causal.

Para profundizar

Lecturas recomendadas

- Wooldridge, *Introductory Econometrics*, caps. 2–8.
- Angrist & Pischke, *Mostly Harmless Econometrics*, cap. 3.
- Hansen, *Econometrics* (gratis online), caps. 2–4.

¡Gracias!