Clase 15: Series temporales

Componentes | Transformaciones | Promedios móviles | Descomposición | Desestacionalización | Empalme | Interpolación

Nicolás Sidicaro

Ciencia de Datos para Economía y Negocios | FCE-UBA

Conceptos fundamentales

¿Qué es una serie temporal?

Definición

Una **serie temporal** (o serie de tiempo) es una secuencia de observaciones de una variable, ordenadas e indexadas en el tiempo.

Diferencias con otros tipos de datos

- **Corte transversal**: muchos individuos, un momento. Ej.: encuesta de hogares en un trimestre.
- **Serie temporal**: un individuo (o agregado), muchos momentos. Ej.: IPC mensual 2010–2024.
- **Datos de panel**: muchos individuos, muchos momentos. Ej.: PBI de 50 países, 30 años.

Implicancia clave

El **orden importa**: las observaciones no son intercambiables. Cada valor depende potencialmente de los anteriores.

Ejemplos en economía

Tres series económicas simuladas

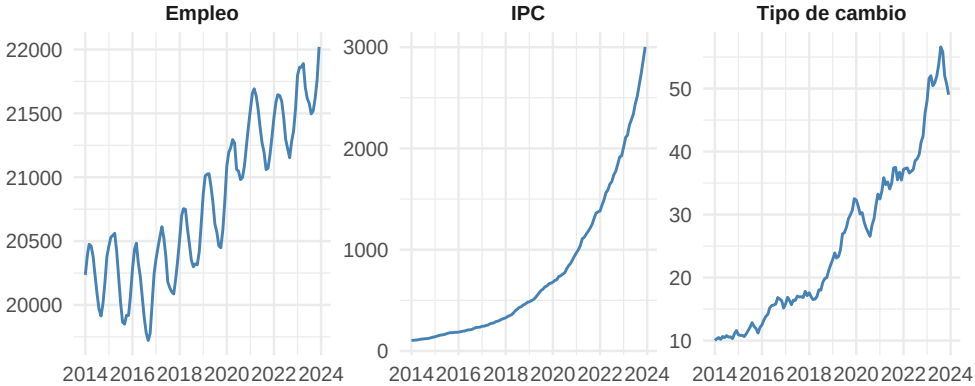

Cada serie tiene características distintas: tendencia, estacionalidad, volatilidad, quiebres.

Componentes de una serie temporal

Las cuatro piezas

- **Tendencia (T)**: dirección de **largo plazo** de la serie (crecimiento, declive).
- **Estacionalidad (S)**: patrón periódico y regular, asociado al **calendario** (meses, trimestres, días de la semana).
- **Ciclo (C)**: fluctuaciones de **mediano plazo** no ligadas al calendario (ciclo económico, ciclo electoral). Diferencia clave con S: el ciclo no tiene frecuencia fija.
- **Ruido / Irregular (I)**: componente **aleatorio** no explicado por los anteriores.

En la práctica

Muchas veces T y C se estiman juntos como "ciclo-tendencia" porque son difíciles de separar en series cortas.

Componentes: visualización

Descomposición aditiva: Y = T + S + I

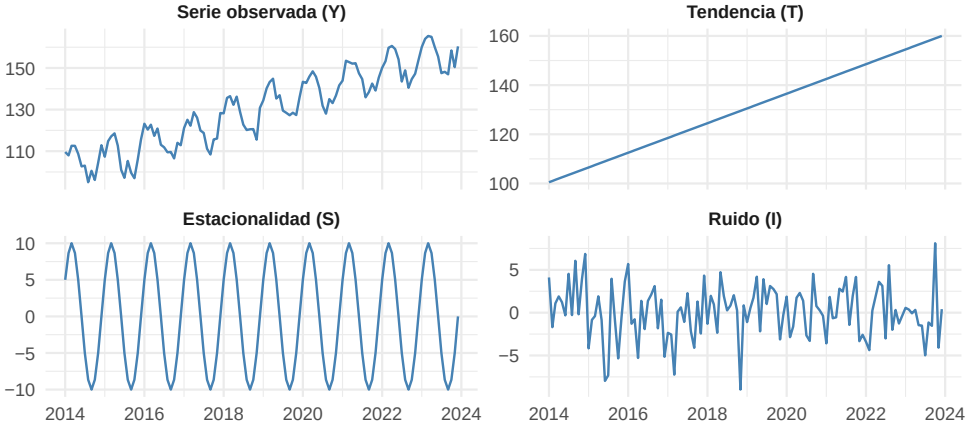

Descomposición aditiva vs. multiplicativa

Dos formas de combinar los componentes

- **Aditiva**: $Y_t = T_t + S_t + I_t \quad \longrightarrow$ la amplitud estacional es **constante** en el tiempo.
- **Multiplicativa**: $Y_t = T_t \times S_t \times I_t \quad \longrightarrow$ la amplitud estacional **crece con el nivel** de la serie.

Criterio de elección

- **Visual**: si la "oscilación" se ensancha cuando la serie sube $\rightarrow$ multiplicativa.
- **Económico**: series de precios y cantidades suelen ser multiplicativas; tasas de interés, aditivas.

El truco del logaritmo

$\log(Y) = \log(T) + \log(S) + \log(I)$: tomar logaritmos convierte una descomposición **multiplicativa** en **aditiva**. Es una transformación muy usada en la práctica.

Aditiva vs. multiplicativa: ejemplo visual

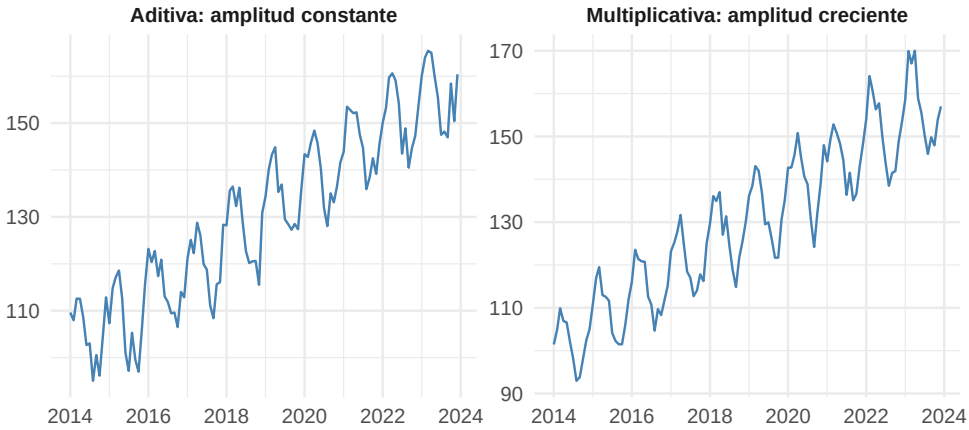

Izquierda: la oscilación estacional tiene el mismo tamaño siempre. Derecha: la oscilación crece con el nivel de la serie.

Frecuencia y periodicidad

Definiciones

- **Frecuencia temporal**: cada cuánto se observa la variable (diaria, mensual, trimestral, anual).
- **Período estacional (s)**: cantidad de observaciones que completan un ciclo estacional.

Frecuencia	Período estacional (s)	Ejemplo
Diaria	$s = 7$ (semanal)	Ventas en supermercados
Mensual	$s = 12$	IPC, empleo registrado
Trimestral	$s = 4$	PBI, balanza de pagos
Anual	—	PBI per cápita

Requisito de regularidad

El análisis clásico de series temporales requiere un índice temporal **regular**: sin saltos, sin duplicados, sin huecos. Las irregularidades distorsionan promedios móviles, descomposiciones y modelos.

Transformaciones estándar

Indexación y cambio de base

¿Qué es un número índice?

Un número índice expresa el valor de una variable como **proporción de un valor de referencia** (base):

$$I_t = \frac{X_t}{X_{\text{base}}} \times 100$$

¿Para qué sirve?

- Comparar la **evolución** de series con unidades o escalas distintas.
- Visualizar trayectorias relativas desde un punto de partida común.

Cambio de base

Si tengo un índice con base t_0 y quiero pasarlo a base t_1:

$$I_t^{(t_1)} = \frac{I_t^{(t_0)}}{I_{t_1}^{(t_0)}} \times 100$$

Deflactación

El problema

Las variables en **precios corrientes** (nominales) mezclan cambios en cantidades con cambios en precios. Para aislar el componente real hay que **deflactar**.

Procedimiento

$$X_t^{\text{real}} = \frac{X_t^{\text{nominal}}}{\text{Deflactor}_t} \times 100$$

¿Qué deflactor usar?

- **IPC**: salarios, ingresos de hogares, canasta de consumo.
- **IPIm**: costos de producción, insumos industriales.
- **Deflactor del PBI**: agregados macroeconómicos.

Variaciones y diferencias

Variación porcentual simple (respecto al período anterior)

$$\Delta\%X_t = \frac{X_t - X_{t-1}}{X_{t-1}} \times 100$$

Variación interanual

$$\Delta\%_{\text{ia}}X_t = \frac{X_t - X_{t-s}}{X_{t-s}} \times 100$$

Donde s es el período estacional (12 para datos mensuales, 4 para trimestrales). Compara el mismo período de años distintos: neutraliza la estacionalidad.

Trampas comunes

- Las variaciones porcentuales **no se suman**: la acumulación requiere **producto** $(1 + r_1)(1 + r_2)\cdots$
- Las **log-diferencias** aproximan a la variación porcentual: $\Delta \log X_t \approx \Delta\%X_t/100$ para cambios pequeños. Son aditivas, simétricas y muy usadas en economía.

Promedios móviles

Promedios móviles simples

Definición

El promedio móvil de orden k es el promedio aritmético de las últimas k observaciones:

$$MA_t^{(k)} = \frac{1}{k} \sum_{j=0}^{k-1} X_{t-j}$$

Dos variantes principales

- **Trailing** (rezagado): usa las k observaciones más recientes, incluyendo X_t. No requiere datos futuros; útil para aplicaciones en tiempo real.
- **Centrado**: toma $k/2$ observaciones antes y después del punto central. Produce una estimación más suave de la tendencia, pero no se puede calcular en los extremos de la serie.

El efecto suavizador

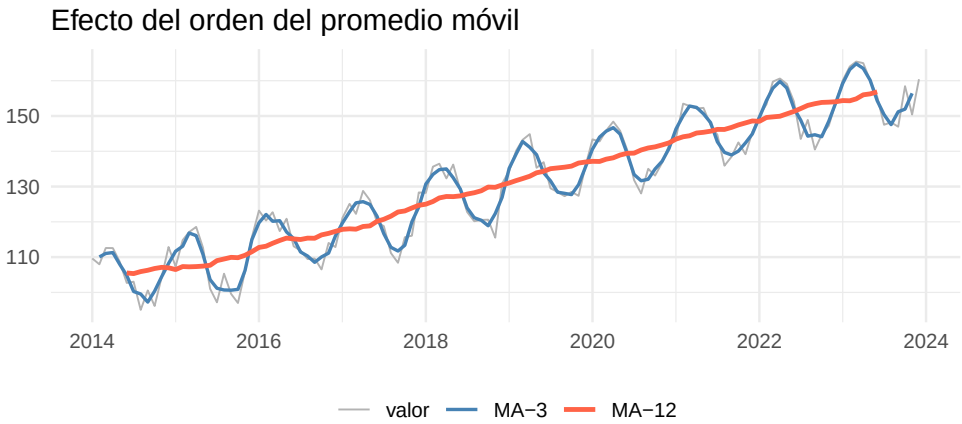

A mayor k, más suavizado: el MA-12 elimina la estacionalidad porque promedia exactamente un ciclo.

Variantes: ponderado y exponencial

Promedio móvil ponderado

Asigna mayor **peso a las observaciones más recientes**:

$$WMA_t = \frac{\sum_{j=0}^{k-1} w_j \cdot X_{t-j}}{\sum_{j=0}^{k-1} w_j}$$

Promedio móvil exponencial (EMA)

Actualización recursiva donde el peso decae **exponencialmente**:

$$EMA_t = \alpha \cdot X_t + (1 - \alpha) \cdot EMA_{t-1}$$

con $\alpha \in (0, 1)$. A mayor α, más peso al dato reciente; a menor α, más suavizado.

Usos

Usos principales

- **Estimar tendencia**: ventana amplia, peso uniforme o exponencial.
- **Eliminar estacionalidad**: ventana = período estacional (ej.: MA-12 en series mensuales).

Descomposición formal

Descomposición clásica

Algoritmo

1. Estimar la **tendencia** ($\hat{T}$) con un promedio móvil centrado de orden s.
2. Calcular el componente de **estacionalidad + ruido**:
   - Aditiva: $Y_t - \hat{T}_t$
   - Multiplicativa: $Y_t / \hat{T}_t$
3. Promediar por subperíodo (ej.: todos los eneros) $\rightarrow$ factor estacional ($\hat{S}$).
4. El **residuo**: $\hat{I}_t = Y_t - \hat{T}_t - \hat{S}_t \quad (\text{o } Y_t/(\hat{T}_t \cdot \hat{S}_t))$.

Limitaciones

- Supone **estacionalidad constante** en el tiempo.
- No produce estimaciones en los **extremos** de la serie (pierde $s/2$ obs. a cada lado).
- Sensible a **outliers**: un valor atípico contamina el promedio móvil.

STL: descomposición con LOESS

Idea central

STL (*Seasonal-Trend decomposition using Loess*) aplica suavizado local (**LOESS**) de forma iterativa para separar tendencia y estacionalidad.

Ventajas sobre la descomposición clásica

- La estacionalidad **puede variar** en el tiempo (no se asume constante).
- Es **robusto** a valores atípicos (usando pesos iterativos).
- El usuario controla las ventanas de suavizado: **ventana estacional** y **ventana de tendencia**.

Limitación principal

STL solo admite formulación **aditiva**. Si la serie es multiplicativa, se aplica STL sobre $\log(Y)$ y luego se exponencia.

Descomposición clásica vs. STL

Dimensión	Descomposición clásica	STL
Estacionalidad	Constante en el tiempo	Puede variar en el tiempo
Robustez	Sensible a outliers	Robusto (pesos iterativos)
Formulación	Aditiva o multiplicativa	Solo aditiva (usar log para mult.)
Extremos de la serie	Pierde $s/2$ observaciones	Produce estimaciones completas
Transparencia	Muy simple de entender	Requiere elegir parámetros de LOESS

¿Cuándo usar cada una?

- **Clásica**: como primer acercamiento didáctico; series cortas y simples.
- **STL**: cuando la estacionalidad evoluciona, hay outliers o se necesita robustez.

Desestacionalización

¿Por qué desestacionalizar?

El problema

Comparar el **mismo mes entre dos años** es fácil: la estacionalidad se cancela. Pero comparar **dos meses consecutivos** (¿el empleo subió de junio a julio?) requiere separar la variación estacional de la variación "genuina" de ciclo-tendencia.

Usos concretos

- Institutos de estadística (INDEC, BLS, Eurostat): publican series desestacionalizadas para comunicación pública.
- Bancos centrales (BCRA, Fed): decisiones de política monetaria sobre datos de ciclo-tendencia.
- Análisis coyuntural: detectar cambios de tendencia sin que el "ruido estacional" confunda.

Clave

La desestacionalización no es una transformación inocua: involucra supuestos y genera revisiones. Siempre hay que comunicar qué método se usó.

Método de factores estacionales

Idea

Calcular el factor estacional promedio para cada subperíodo (cada mes, cada trimestre) y usarlo para "limpiar" la serie.

Procedimiento

1. Estimar la tendencia con MA centrado.
2. Calcular el ratio (o diferencia) $Y_t/\hat{T}_t$ para cada observación.
3. Promediar los ratios de cada subperíodo $\rightarrow \hat{S}_{\text{mes}}$.
4. Serie desestacionalizada: $Y_t^{SA} = Y_t/\hat{S}_{\text{mes}}$ (multiplicativa).

Limitación

Supone estacionalidad **estable y determinística**: el factor de enero es siempre el mismo. Inadecuado si el patrón estacional evoluciona.

X-13ARIMA-SEATS

¿Qué es?

El método estándar internacional de desestacionalización, desarrollado por el **US Census Bureau**. Usado por INDEC, Eurostat, BLS, y la mayoría de institutos de estadística.

Dos módulos complementarios

- **X-11**: filtros iterativos (Henderson) para extraer tendencia y estacionalidad.
- **SEATS**: descomposición espectral basada en modelos ARIMA.

Capacidades

Detección automática de **outliers**, ajuste por **efectos de calendario**, años bisiestos, festivos móviles (Semana Santa, Pascua).

Limitaciones

"Caja negra" con muchos parámetros internos. Requiere series **largas** ($\geq$ 3 años, idealmente $\geq$ 5). Las últimas observaciones se **revisan retroactivamente** al incorporar datos nuevos.

STL como alternativa a X-13

Ventajas de STL

- Más **transparente** e interpretable que X-13.
- Más flexible en la definición de la **ventana estacional**.
- Código abierto, fácil de implementar en R.

Limitación frente a X-13

No maneja **efectos de calendario** automáticamente. Solución posible: combinar STL con una **regresión** previa para remover efectos de calendario (días hábiles, festivos móviles).

En la práctica

- Para publicación oficial con requerimientos de comparabilidad internacional $\rightarrow$ **X-13**.
- Para análisis propio, investigación o enseñanza $\rightarrow$ **STL** suele ser suficiente y más didáctico.

Consideraciones prácticas

¿Qué publicar?

- **Serie original**: dato "crudo", sin intervención.
- **Serie desestacionalizada**: sin el componente estacional (SA = *seasonally adjusted*).
- **Ciclo-tendencia**: la señal más suave, sin estacionalidad ni ruido.

La elección depende del público y el objetivo de comunicación.

Problemas en el extremo de la serie

- Las **últimas observaciones** son las más revisadas al incorporar datos nuevos.
- Esto genera **revisiones retroactivas**: el dato desestacionalizado de hoy puede cambiar mañana.
- Implicancia: los análisis coyunturales basados en las últimas observaciones son inherentemente provisorios.

Empalme de series

¿Por qué empalmar?

El problema

Las series económicas largas suelen tener **quiebres** por:

- Cambios metodológicos: nuevo año base del IPC, nueva clasificación industrial.
- Cambios de fuente: reemplazo de una encuesta por otra.
- Discontinuidades institucionales: fusión de organismos, modificación de registros.

Objetivo

Reconstruir una serie **larga y coherente** para análisis histórico, combinando dos o más tramos que no son directamente comparables.

Requisito

Necesitamos un **período de superposición** (*overlap*): al menos un tramo donde ambas series coexistan para medir la brecha entre ellas.

Método por diferencia (empalme aditivo)

Supuesto

El quiebre entre las dos series es **aditivo y constante**: la serie nueva es igual a la vieja más (o menos) una constante.

Procedimiento

1. Calcular la brecha en el punto de empalme: $d = X_t^{\text{nueva}} - X_t^{\text{vieja}}$
2. Sumar d a todos los valores de la serie antigua: $X_t^{\text{emp}} = X_t^{\text{vieja}} + d$

Cuándo aplica

Series en niveles sin tendencia pronunciada, brechas pequeñas.

Problema

Puede generar niveles sin sentido económico: valores negativos en variables que no lo admiten, o valores fuera de rango razonable.

Método por cociente (retropolación multiplicativa)

Supuesto

El quiebre es **multiplicativo**: la serie nueva es proporcional a la vieja.

Procedimiento

1. Calcular el ratio en el punto de empalme: $r = X_t^{\text{nueva}} / X_t^{\text{vieja}}$
2. Multiplicar toda la serie antigua por r: $X_t^{\text{emp}} = X_t^{\text{vieja}} \times r$

Cuándo aplica

Índices de precios, series con crecimiento, variables estrictamente positivas.

Problema

Si el ratio es muy distinto de 1, distorsiona toda la historia: los niveles antiguos se "inflan" o "deprimen" uniformemente.

Encadenamiento por tasas de variación

Idea

Preservar la **dinámica** (variaciones) de la serie antigua, no sus niveles. Se reconstruye la serie hacia atrás desde el punto de empalme.

Procedimiento

1. Tomar el nivel de la serie nueva en el punto de empalme: $X_{t_0}^{\text{emp}} = X_{t_0}^{\text{nueva}}$.
2. Hacia atrás, reconstruir con las variaciones de la serie vieja:

$$X_{t-1}^{\text{emp}} = \frac{X_t^{\text{emp}}}{1 + \Delta\%_t^{\text{vieja}}/100}$$

Ventaja

La dinámica histórica es **fiel a los datos originales**: las tasas de variación de la serie empalmada coinciden con las de la serie vieja.

Criterios de elección del empalme

¿Cómo decidir?

1. **Overlap**: a más períodos de superposición, mejor estimación del ratio o brecha.
2. **Naturaleza del quiebre**: ¿el cambio metodológico afecta el nivel (aditivo) o la escala (multiplicativo)?
3. **Análisis visual**: comparar la serie empalmada con las originales; buscar discontinuidades artificiales.
4. **Validación**: las variaciones porcentuales deben ser coherentes en el punto de unión.

Método	Preserva	Mejor para
Diferencia (aditivo)	Niveles relativos	Brechas pequeñas, variables acotadas
Cociente (multiplicativo)	Proporciones	Índices, series positivas
Tasas de variación	Dinámica / crecimiento	Análisis de largo plazo

No hay método universalmente correcto

El supuesto sobre la naturaleza del quiebre define el método.

Datos faltantes e interpolación

Tipos de datos faltantes

Clasificación

- **MCAR** (*Missing Completely at Random*): la ausencia es completamente aleatoria, sin relación con ninguna variable. Ej.: un sensor falló por causas mecánicas.
- **MAR** (*Missing at Random*): la probabilidad de ausencia depende de variables **observables**. Ej.: los municipios chicos reportan menos datos.
- **Estructural / Sistemático**: la ausencia tiene una razón determinista. Ej.: no hay dato de PBI trimestral antes de cierto año; el mercado cierra los feriados.

¿Por qué importa la distinción?

Cada tipo habilita métodos de imputación distintos. Interpolar datos MCAR es razonable; interpolar datos faltantes estructurales puede ser una ficción peligrosa.

Interpolación vs. extrapolación

Definiciones

- **Interpolación**: estimar valores **dentro** del rango de datos conocidos (llenar un hueco entre dos puntos observados).
- **Extrapolación**: estimar valores **fuera** del rango $\rightarrow$ incertidumbre mucho mayor.

Cuándo es válido interpolar

- Gaps **cortos** (pocos períodos faltantes).
- Serie **suave** (sin saltos bruscos).
- Datos MCAR o MAR.

Cuándo NO interpolar

Datos faltantes **estructurales**, gaps **largos**, quiebres en el proceso generador de datos. En esos casos, interpolar inventa una dinámica que no existió.

LOCF y NOCB

Forward fill (LOCF: *Last Observation Carried Forward*)

Propaga el último valor conocido hacia adelante: $X_t = X_{t_{\text{último obs.}}}$

Backward fill (NOCB: *Next Observation Carried Backward*)

Propaga el siguiente valor conocido hacia atrás.

Cuándo aplica

Variables de **stock** que no cambian hasta nueva observación: salario mínimo, tipo de cambio con cepo, precio regulado, tasa de política monetaria entre reuniones del BCRA.

Problema

Genera **escalones artificiales**: la serie salta abruptamente al llegar la nueva observación. Inadecuado para series de **flujo** (ventas, producción, empleo) donde se espera variación continua.

Interpolación lineal

Supuesto

La variable cambia a **ritmo constante en niveles** entre dos puntos conocidos:

$$\hat{X}_t = X_a + \frac{X_b - X_a}{t_b - t_a} \cdot (t - t_a)$$

donde X_a y X_b son los valores observados antes y después del gap.

Cuándo aplica

Series con tendencia suave, gaps cortos, sin estacionalidad marcada.

Problemas

- No respeta curvatura ni aceleración: la serie interpolada siempre es una recta.
- Ignora la estacionalidad: si faltan los datos de un verano, interpola una recta entre otoño y primavera.

Interpolación exponencial

Supuesto

La variable crece a **tasa constante** entre dos puntos conocidos:

$$\hat{X}_t = X_a \cdot e^{r\cdot(t-t_a)}, \qquad r = \frac{\log(X_b) - \log(X_a)}{t_b - t_a}$$

Equivale a hacer interpolación lineal sobre $\log(X)$.

Cuándo aplica

Variables estrictamente positivas con crecimiento aproximadamente proporcional: **población entre censos** (caso canónico), PBI, masa monetaria, stock de capital.

Ventaja y desventajas

Bueno: nunca genera valores negativos; respeta la naturaleza multiplicativa del crecimiento.
Malo: no captura aceleraciones ni desaceleraciones entre los puntos conocidos.

Interpolación por splines cúbicos

Supuesto

La serie es **suave** con continuidad de primera y segunda derivada en los puntos de unión.

Ventaja

Produce curvas más **naturales** visualmente: respeta la curvatura local de la serie, a diferencia de la interpolación lineal.

Problema: overshoot

Con gaps largos o cambios bruscos, el spline puede **oscilar fuera del rango observado** (*overshoot*): genera picos o valles artificiales.

Alternativa: interpolación de Stineman

Diseñada para preservar la **monotonía local**: si los datos suben entre dos puntos, la interpolación también sube, sin oscilaciones artificiales. Menos conocida pero muy robusta en la práctica.

Métodos de interpolación: comparación visual

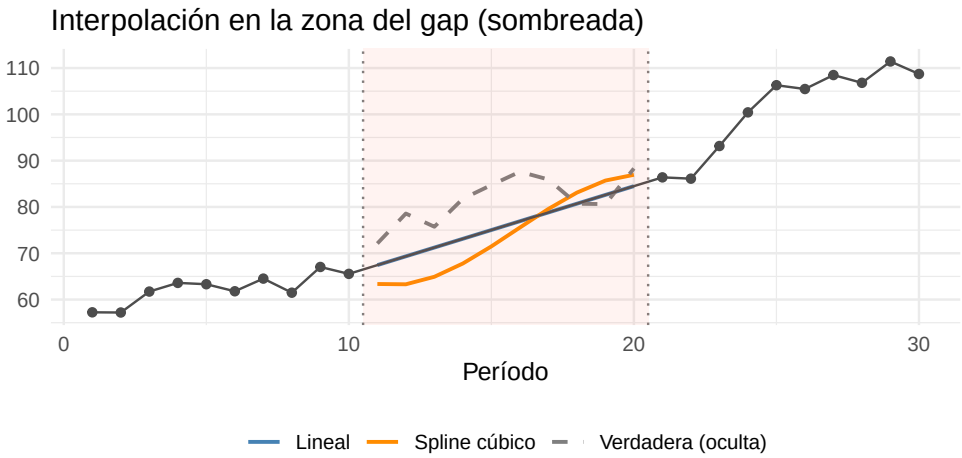

Interpolación con indicador auxiliar

El problema

Tenemos una variable de **baja frecuencia** (anual) y queremos desagregarla a **alta frecuencia** (mensual o trimestral).

La idea (Denton / Chow-Lin)

Usar un **indicador de alta frecuencia** correlacionado con la variable de interés para distribuir el total:

- La serie de alta frecuencia resultante **suma el total anual** observado.
- La **dinámica intra-anual** sigue la del indicador auxiliar.

Supuesto clave

La dinámica del indicador **refleja** la dinámica de la variable de interés. Si el indicador no es un buen proxy, la desagregación es espuria.

Tabla comparativa: métodos de interpolación

Método	Supuesto	Cuándo usar	Limitación
LOCF / NOCB	Variable no cambia entre obs.	Stocks, precios regulados	Escalones artificiales
Lineal	Cambio constante en niveles	Gaps cortos, serie suave	Ignora curvatura y estacionalidad
Exponencial	Tasa de crecimiento cte.	Población, variables con crecimiento proporcional	No capta cambios de dinámica
Spline cúbico	Suavidad de 2da derivada	Series suaves, gaps moderados	Overshoot con gaps largos
Stineman	Monotonía local	Cambios de dirección abruptos	Menos difundido
Denton / Chow-Lin	Indicador capta la dinámica	Desagregación temporal	Requiere indicador confiable